FPT UNIVERSITY

## DPL302m Project

# ASSIGNMENT REPORT

## LEGALBOT – SMART LEGAL ASSISTANT

**Instructor: Luong Trung Kien**


| Student Name | Student ID |
|---|---|
| 1. Pham Trung Tung | HE187331 |
| 2. Nguyen Van Thuc | HE181431 |
| 3. Truong Minh Phuong | HE181016 |
| 4. Hoang Quoc Dung | HE181505 |

# Contents


**1 Abstract** **3**

**2 Introduction** **3**

2.1 Introduction to the chosen field and the reasons for selecting it . . . . 3

2.2 The problem and the project's objectives . . . . . 4

2.3 Overview of the project implementation stages . . . . . 5

**3 Data Collection and Processing** **6**

3.1 Data sources . . . . . 6

3.2 Data Quantity and Scope . . . . . 7

3.3 Data Characteristics . . . . . 9

3.4 Data Storage Methods . . . . . 10

**4 Text Analysis and Classification** **10**

4.1 Identifying Key Information/Topics for Classification . . . . . 10

4.2 Classification Method . . . . . 10

4.2.1 Data Collection . . . . . 11

4.2.2 Model Training . . . . . 11

4.2.3 Model Performance Evaluation . . . . . 11

4.2.4 Results Analysis and Discussion . . . . . 12

4.2.5 Conclusion . . . . . 12

**5 Chatbot Deployment** **13**

5.1 Chatbot Design Description . . . . . 13

5.2 Details on Chatbot Development . . . . . 14

5.2.1 Embedding data and loading data into the database . . . . . 14

5.2.2 Finetune the Llama 3.2 3B model for question decomposition 15

5.2.3 Fine-tune the Pho-BERT model for question classification . . 16

5.2.4 Chatbot Performance Evaluation . . . . . 17

5.2.5 Discussion on possible improvements for the Chatbot . . . . . 18

**6 Data Analysis, Summarization and Reporting 19**

6.1 Model Decomposition Data . . . . . 19

6.1.1 Data statistics . . . . . 19

6.1.2 Related graphs . . . . . 20

6.1.3 wordcloud of user_query . . . . . 21

6.1.4 Cosine Similarity between user_query and decomposed_queries 23

6.2 Classification model data . . . . . 24

6.2.1 Label distribution . . . . . 24

6.2.2 Query length distribution . . . . . 24

6.2.3 Query wordcloud analysis . . . . . 25

6.2.4 Query statistical data analysis . . . . . 26

6.3 Law data . . . . . 27

6.3.1 Statistics of quantity . . . . . 27

6.3.2 Number of chunks by label . . . . . 28

6.3.3 Percentage of each type of law . . . . . 29

6.3.4 Word cloud chart and word frequency distribution . . . . . 30

**7 Conclusion 31**

7.1 Summary of key project results . . . . . 31

7.2 Project Contributions . . . . . 31

7.3 Limitations and future development directions of the project . . . . . 31

7.3.1 Existing limitations . . . . . 31

7.3.2 Future development directions of the project . . . . . 32

**8 References 32**

# 1 Abstract

With the goal of helping people address questions related to legal documents on population, marriage and family, children, gender equality, and domestic violence, the members of the OPENAPI group have collaborated to develop the project "Legal Bot-Smart Legal Assistant." The project's objective is to make legal information more accessible and enable quick, accurate searches for the public.

The chatbot utilizes advanced models in natural language processing (NLP) and deep learning to enhance the accuracy of its responses. Specifically, the system employs the Vietnamese document embedding model to generate vector representations of texts, which are then stored in a vector database and queried using Faiss for similarity-based search. When a user inputs a query, the chatbot breaks it down into smaller questions, embedding each sentence, using PhoBERT to classify the appropriate topic, and retrieving relevant data. Finally, a large language model (Ollama) synthesizes and generates a response for the user.

After the construction and training process with the collected data, the chatbot has achieved good performance based on evaluation metrics [METRIC], [METRIC], and [METRIC]. The results show that the system can provide accurate and contextually relevant answers, helping users search for information more effectively. The project opens up the potential for AI applications in legal assistance, contributing to improving the public's access to legal information.

# 2 Introduction

## 2.1 Introduction to the chosen field and the reasons for selecting it

Population, marriage and family, children, gender equality, and domestic violence prevention are not only personal issues but also have a significant impact on the economic and social development of each country. Children are the future of the nation, yet many children in Vietnam still do not have full access to education, healthcare, and a safe living environment. Issues such as violence, child labor exploitation, child marriage, and sexual abuse against children still persist. In Vietnam, according to Law No. 102/2016/QH13, children's basic rights are defined, including the right to be protected, cared for, educated, the right to privacy, and the strict handling of child abuse cases. However, enforcement remains challenging, particularly in cases related to domestic violence, school bullying, and child protection in cyberspace.

First of all, population is not merely a statistical number but also reflects issues related to economic growth, social welfare, and the quality of life. Vietnam is currently entering a phase of rapid population aging, which presents many challenges in labor, healthcare, and the social security system. The decreasing birth rate, along with an increasing life expectancy, puts great pressure on ensuring a sustainable workforce and providing care for the elderly.

Additionally, domestic violence is a pressing issue that affects not only the direct

victims but also has negative social impacts. Although the Law on Domestic Violence Prevention and Control was enacted in 2007, physical, mental, sexual, and economic violence continues, particularly against women and children. Many cases are not reported due to cultural barriers, psychological reluctance, and the ineffectiveness of victim protection. To address this issue, it is necessary to strengthen education, raise public awareness, improve policies for supporting victims, and strictly handle violent behaviors.

Furthermore, gender equality is an important goal but has not yet been fully achieved. According to Article 4 of Law 73/2006/QH11 on Gender Equality, the goal of gender equality is to eliminate gender discrimination, create equal opportunities for men and women in economic and social development, and human resource development, moving towards genuine gender equality between men and women, and establishing and reinforcing cooperation and support between men and women in all aspects of social and family life. However, women still face disadvantages in accessing economic, political, and social opportunities. Gender stereotypes persist, making it difficult for women to develop careers and participate in leadership positions.

Meanwhile, marriage and family are social foundations, protected by Vietnamese law based on the principles of voluntariness, monogamy, and equality between spouses. However, in reality, many challenges still exist, such as the increasing divorce rate, domestic violence, disputes over child custody, and new legal issues such as international marriages and surrogacy. Specifically, Vietnam does not recognize same-sex marriage but also does not prohibit same-sex unions. Raising awareness and improving the legal framework are necessary to build a more equal and sustainable society.

These issues are major challenges that affect the country's development. The members of the OPENAPI group chose this topic because each member wants to contribute a small part to create a QA chatbot that helps people better understand children's rights, prevent domestic violence, and gain a clearer perspective on marriage and family, as well as population planning.

## 2.2 The problem and the project's objectives

In the context of increasingly improved laws that have a growing impact on the development of society, it is essential for people to access legal documents accurately and quickly. However, the legal system is often very complex, difficult to understand, and easily fragmented, causing many difficulties in searching, consulting, and applying the correct regulations. Although government agencies have compiled valid legal documents in the Legal Code system, the structure and content of the Legal Code are often hard to read for the public. Additionally, searching for these documents in the Legal Code is challenging due to the inefficient information retrieval system. This results in significant obstacles for both legal professionals and the public.

In particular, areas such as Children, Gender Equality, Marriage and Family, Domestic Violence, and Population directly affect the rights and duties of many groups in society. These are critical areas that directly impact the future development of the country. Understanding the law on these topics will not only enhance personal awareness but also make the implementation of legal documents by the state more effective.

The legal QA assistant project was developed to create an intelligent chatbot that addresses this issue. The goal of the project is to help people easily access and look up legal documents still in effect, related to the areas mentioned above. By applying artificial intelligence (AI) and natural language processing (NLP) techniques, the project aims to transform complex legal information into easily understandable language, helping people to easily remember and apply it. With a focus on areas such as Children, Gender Equality, Marriage and Family, Domestic Violence, and Population, the system ensures the provision of in-depth information about the laws, decrees, and circulars currently in effect, helping to raise public awareness and promote transparency and fairness in society.

## 2.3 Overview of the project implementation stages

**Phase 1: Data Collection and Processing (Week 1)**

- Select Chapter 8 on Phap dien.
- Using Web crawlers to extract text from PDFs and docs.
- Chunking data and storing data in jsonl format.
- Embedding data and storing in Faiss.

**Phase 2: Data Analysis and Classification (Week 2)**

- Identifying topics for the classification question.
- Using PhoBERT for text classification.
- Evaluating the performance of the model.

**Phase 3: Chatbot Development (Week 3)**

- Design of the chatbot pipeline (RAG).
- Fine-tuning Llama 3.2B to decompose user questions.
- Integrating the Faiss index and building the chatbot.
- Testing and evaluating chatbot performance.

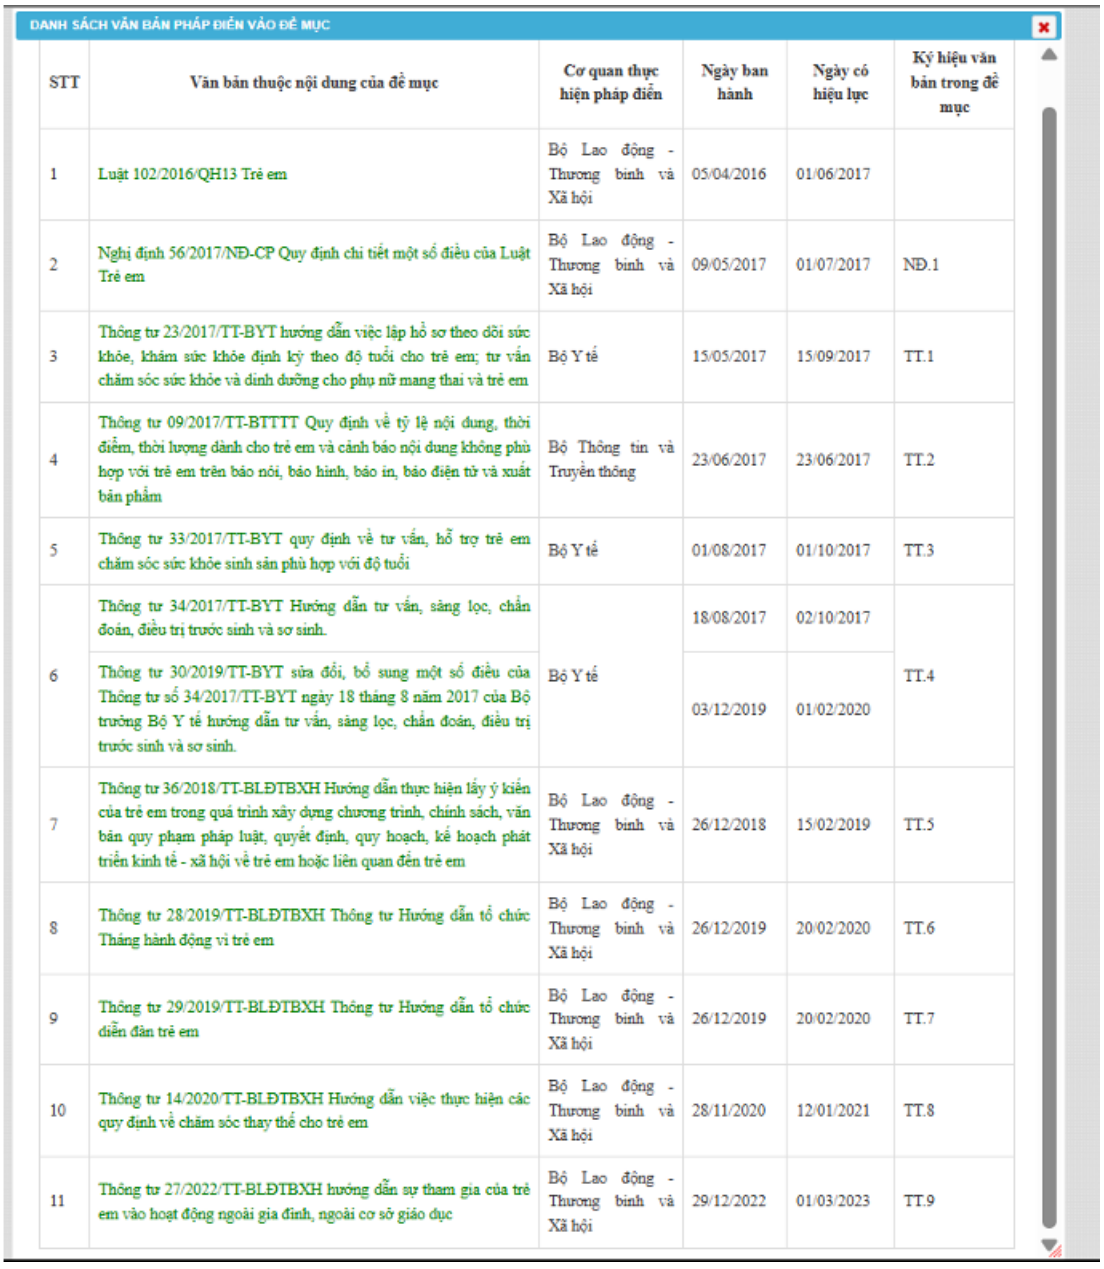
**Phase 4: Data Analysis and Reporting (Week 4)**

- Conducting statistical analysis and data visualization.
- Writing the final report and preparing the presentation.
- Presenting the results of the project to the class.

# 3 Data Collection and Processing

## 3.1 Data sources

The data set was collected from the ”Phap dien” database (part of the Government Electronic Portal) and official information pages of ministries and agencies related to Population, Family, Children and Gender Equality. Specifically, the team accessed:



DANH SÁCH VĂN BẢN PHÁP ĐIỂN VÀO ĐỀ MỤC

| STT | Văn bản thuộc nội dung của đề mục | Cơ quan thực hiện pháp điển | Ngày ban hành | Ngày có hiệu lực | Ký hiệu văn bản trong đề mục |
|---|---|---|---|---|---|
| 1 | Luật 102/2016/QH13 Trẻ em | Bộ Lao động - Thương binh và Xã hội | 05/04/2016 | 01/06/2017 | |
| 2 | Nghị định 56/2017/NĐ-CP Quy định chi tiết một số điều của Luật Trẻ em | Bộ Lao động - Thương binh và Xã hội | 09/05/2017 | 01/07/2017 | NĐ.1 |
| 3 | Thông tư 23/2017/TT-BYT hướng dẫn việc lập hồ sơ theo dõi sức khỏe, khám sức khỏe định kỳ theo độ tuổi cho trẻ em; tư vấn chăm sóc sức khỏe và dinh dưỡng cho phụ nữ mang thai và trẻ em | Bộ Y tế | 15/05/2017 | 15/09/2017 | TT.1 |
| 4 | Thông tư 09/2017/TT-BTTTT Quy định về tỷ lệ nội dung, thời điểm, thời lượng dành cho trẻ em và cảnh báo nội dung không phù hợp với trẻ em trên báo nói, báo hình, báo in, báo điện tử và xuất bản phẩm | Bộ Thông tin và Truyền thông | 23/06/2017 | 23/06/2017 | TT.2 |
| 5 | Thông tư 33/2017/TT-BYT quy định về tư vấn, hỗ trợ trẻ em chăm sóc sức khỏe sinh sản phù hợp với độ tuổi | Bộ Y tế | 01/08/2017 | 01/10/2017 | TT.3 |
| 6 | Thông tư 34/2017/TT-BYT Hướng dẫn tư vấn, sàng lọc, chẩn đoán, điều trị trước sinh và sơ sinh. | Bộ Y tế | 18/08/2017 | 02/10/2017 | TT.4 |
| | Thông tư 30/2019/TT-BYT sửa đổi, bổ sung một số điều của Thông tư số 34/2017/TT-BYT ngày 18 tháng 8 năm 2017 của Bộ trưởng Bộ Y tế hướng dẫn tư vấn, sàng lọc, chẩn đoán, điều trị trước sinh và sơ sinh. | | 03/12/2019 | 01/02/2020 | |
| 7 | Thông tư 36/2018/TT-BLĐTBXH Hướng dẫn thực hiện lấy ý kiến của trẻ em trong quá trình xây dựng chương trình, chính sách, văn bản quy phạm pháp luật, quyết định, quy hoạch, kế hoạch phát triển kinh tế - xã hội về trẻ em hoặc liên quan đến trẻ em | Bộ Lao động - Thương binh và Xã hội | 26/12/2018 | 15/02/2019 | TT.5 |
| 8 | Thông tư 28/2019/TT-BLĐTBXH Thông tư Hướng dẫn tổ chức Tháng hành động vì trẻ em | Bộ Lao động - Thương binh và Xã hội | 26/12/2019 | 20/02/2020 | TT.6 |
| 9 | Thông tư 29/2019/TT-BLĐTBXH Thông tư Hướng dẫn tổ chức diễn đàn trẻ em | Bộ Lao động - Thương binh và Xã hội | 26/12/2019 | 20/02/2020 | TT.7 |
| 10 | Thông tư 14/2020/TT-BLĐTBXH Hướng dẫn việc thực hiện các quy định về chăm sóc thay thế cho trẻ em | Bộ Lao động - Thương binh và Xã hội | 28/11/2020 | 12/01/2021 | TT.8 |
| 11 | Thông tư 27/2022/TT-BLĐTBXH hướng dẫn sự tham gia của trẻ em vào hoạt động ngoài gia đình, ngoài cơ sở giáo dục | Bộ Lao động - Thương binh và Xã hội | 29/12/2022 | 01/03/2023 | TT.9 |

Figure 1: Data in Phap Dien

| STT | Văn bản thuộc nội dung của đề mục | Cơ quan thực hiện pháp điển | Ngày ban hành | Ngày có hiệu lực | Ký hiệu văn bản trong đề mục |
|---|---|---|---|---|---|
| 1 | Luật 73/2006/QH11 Bình đẳng giới | Bộ Lao động - Thương binh và Xã hội | 29/11/2006 | 01/07/2007 | |
| 2 | Nghị định 70/2008/NĐ-CP Quy định chi tiết thi hành một số điều của Luật Bình đẳng giới | Bộ Lao động - Thương binh và Xã hội | 04/06/2008 | 03/07/2008 | NĐ.1 |
| 3 | Nghị định 48/2009/NĐ-CP Quy định về các biện pháp bảo đảm bình đẳng giới | Bộ Lao động - Thương binh và Xã hội | 19/05/2009 | 15/07/2009 | NĐ.2 |
| 4 | Quyết định 114/2008/QĐ-TTg Về việc kiện toàn Ủy ban quốc gia vì sự tiến bộ của phụ nữ Việt Nam | Bộ Lao động - Thương binh và Xã hội | 22/08/2008 | 22/08/2008 | QĐ.1 |
| 5 | Thông tư 191/2009/TT-BTC Hướng dẫn quản lý và sử dụng kinh phí hoạt động bình đẳng giới và hoạt động vì sự tiến bộ của phụ nữ | Bộ Tài chính | 01/10/2009 | 15/11/2009 | TT.1 |

Figure 2: Data in Phap Dien

The list of legal documents categorized under ”Topic 8: Population, Family, Children, Gender Equality,”which includes five subcategories:

- Children
- Gender Equality
- Population
- Marriage and Family
- Prevention of Domestic Violence

The detailed legal documents referenced from this category list (e.g., Laws, Decrees, Circulars, Decisions, etc.).

## 3.2 Data Quantity and Scope

- **Number of documents**: A total of 44 legal documents were collected, corresponding to the list shown in the screenshots.
- **Time span**: The documents range from approximately 2003 to 2023 (based on the displayed information, with specific adjustments depending on each document).
- **Classification**: These documents are categorized into the five subtopics mentioned above, corresponding to specific legal content groups (Children, Gender Equality, Population, Marriage and Family, and Prevention of Domestic Violence).

| STT | Văn bản thuộc nội dung của đề mục | Cơ quan thực hiện pháp điển | Ngày ban hành | Ngày có hiệu lực | Ký hiệu văn bản trong đề mục |
|---|---|---|---|---|---|
| 1 | Pháp lệnh 06/2003/PL-UBTVQH11 Dân số | | 09/01/2003 | 01/05/2003 | |
| 2 | Nghị định 104/2003/NĐ-CP Quy định chi tiết và hướng dẫn thi hành một số điều của Pháp lệnh Dân số | | 16/09/2003 | 05/10/2003 | NĐ.1 |
| 3 | Nghị định 20/2010/NĐ-CP Quy định chi tiết thi hành Pháp lệnh sửa đổi Điều 10 của Pháp lệnh Dân số | | 08/03/2010 | 29/04/2010 | NĐ.2 |
| | Nghị định 18/2011/NĐ-CP Sửa đổi khoản 6 Điều 2 Nghị định số 20/2010/NĐ-CP ngày 08 tháng 3 năm 2010 của Chính phủ quy định chi tiết thi hành Pháp lệnh Sửa đổi điều 10 của Pháp lệnh Dân số | | 17/05/2011 | 12/05/2011 | |
| 4 | Nghị định 39/2015/NĐ-CP Quy định chính sách hỗ trợ cho phụ nữ thuộc hộ nghèo là người dân tộc thiểu số khi sinh con đúng chính sách dân số | | 27/04/2015 | 15/06/2015 | NĐ.3 |
| 5 | Quyết định 52/2009/QĐ-TTg Phê duyệt Đề án Kiểm soát dân số các vùng biển, đảo và ven biển giai đoạn 2009 – 2020 | | 09/04/2009 | 25/05/2009 | QĐ.1 |
| 6 | Quyết định 17/2013/QĐ-TTg Quy định chức năng, nhiệm vụ, quyền hạn và cơ cấu tổ chức của Tổng cục Dân số - Kế hoạch hóa gia đình thuộc Bộ Y tế | | 12/03/2013 | 10/05/2013 | QĐ.2 |
| 7 | Thông tư 05/2008/TT-BYT Hướng dẫn chức năng, nhiệm vụ và cơ cấu tổ chức bộ máy Dân số - Kế hoạch hóa gia đình ở địa phương | Bộ Y tế | 14/05/2008 | 29/05/2008 | TT.1 |
| 8 | Thông tư 06/2009/TT-BYT Quy định về định mức thuốc thiết yếu và các vật tư tiêu hao trong các dịch vụ, thủ thuật chăm sóc sức khỏe sinh sản | Bộ Y tế | 26/06/2009 | 10/08/2009 | TT.2 |
| 9 | Thông tư 10/2011/TT-BYT Hướng dẫn về biên chế của Trung tâm Dân số - Kế hoạch hóa gia đình huyện, quận, thị xã, thành phố thuộc tỉnh | Bộ Y tế | 25/02/2011 | 26/03/2011 | TT.3 |
| 10 | Thông tư liên tịch 25/2013/TTLT-BYT-BTC Quy định chế độ quản lý tài chính đối với việc thực hiện hoạt động tiếp thị xã hội các phương tiện tránh thai, phòng, chống HIV/AIDS và các bệnh lây truyền qua đường tình dục | | 04/09/2013 | 20/10/2013 | TL.2 |
| 11 | Thông tư 03/2014/TT-BYT Ban hành Danh mục dị tật, bệnh hiểm nghèo không mang tính di truyền để xác định cặp vợ chồng sinh con thứ ba không vi phạm quy định sinh một hoặc hai con | Bộ Y tế | 20/01/2014 | 01/03/2014 | TT.4 |
| 12 | Thông tư liên tịch 07/2016/TTLT-BYT-BTC-BLĐTBXH Quy định chi tiết Nghị định số 39/2015/NĐ-CP ngày 27 tháng 4 năm 2015 của Chính phủ quy định chính sách hỗ trợ cho phụ nữ thuộc hộ nghèo là người dân tộc thiểu số khi sinh con đúng chính sách dân số | | 15/04/2016 | 30/05/2016 | TL.3 |
| | Thông tư 45/2018/TT-BYT sửa đổi, bổ sung một số điều của Thông tư liên tịch số 07/2016/TTLT-BYT-BTC-BLĐTBXH ngày 15 tháng 4 năm 2016 quy định chi tiết Nghị định số 39/2015/NĐ-CP ngày 27 tháng 4 năm 2015 của Chính phủ quy định chính sách hỗ trợ cho phụ nữ thuộc hộ nghèo là người dân tộc thiểu số khi sinh con đúng chính sách dân số | | 28/12/2018 | 01/03/2019 | |
| 13 | Thông tư 01/2021/TT-BYT hướng dẫn một số nội dung để địa phương ban hành chính sách khen thưởng, hỗ trợ đối với tập thể, cá nhân thực hiện tốt công tác dân số | Bộ Y tế | 25/01/2021 | 10/03/2021 | TT.6 |
| | Thông tư 23/2021/TT-BYT sửa đổi, bổ sung một số văn bản quy phạm pháp luật do Bộ trưởng Bộ Y tế ban hành | | 09/12/2021 | 25/01/2022 | |
| 14 | Thông tư 02/2021/TT-BYT Quy định tiêu chuẩn, nhiệm vụ của cộng tác viên dân số | Bộ Y tế | 25/01/2021 | 10/03/2021 | TT.7 |
| 15 | Thông tư 01/2022/TT-BYT Quy định ghi chép ban đầu và chế độ báo cáo thống kê chuyên ngành dân số | Bộ Y tế | 10/01/2022 | 01/03/2022 | TT.8 |
| 16 | Thông tư 34/2023/TT-BYT Hướng dẫn chức năng, nhiệm vụ và quyền hạn của chi cục dân số thuộc sở y tế | Bộ Y tế | 31/12/2023 | 19/02/2024 | TT.9 |

Figure 3: Data in Phap Dien

| STT | Văn bản thuộc nội dung của đề mục | Cơ quan thực hiện pháp điển | Ngày ban hành | Ngày có hiệu lực | Ký hiệu văn bản trong đề mục |
|---|---|---|---|---|---|
| 1 | Luật 52/2014/QH13 Hôn nhân và gia đình | | 19/06/2014 | 01/01/2015 | |
| 2 | Nghị định 02/2013/NĐ-CP Quy định về công tác gia đình | Bộ Văn hóa, Thể thao và Du lịch | 03/01/2013 | 18/02/2013 | NĐ.1 |
| 3 | Nghị định 126/2014/NĐ-CP Quy định chi tiết một số điều và biện pháp thi hành Luật Hôn nhân và gia đình | Bộ Tư pháp | 31/12/2014 | 15/02/2015 | NĐ.2 |
| | Nghị định 123/2015/NĐ-CP Quy định chi tiết một số điều và biện pháp thi hành Luật Hộ tịch | | 15/11/2015 | 01/01/2016 | |
| 4 | Nghị quyết 01/2024/NQ-HĐTP Hướng dẫn áp dụng một số quy định của pháp luật trong giải quyết vụ việc về hôn nhân và gia đình | Tòa án nhân dân tối cao | 16/05/2024 | 01/07/2024 | NQ.1 |
| 5 | Thông tư 12/2013/TT-BVHTTDL Quy định chi tiết hoạt động hỗ trợ xây dựng gia đình hạnh phúc, phát triển bền vững tại cộng đồng | Bộ Văn hóa, Thể thao và Du lịch | 17/12/2013 | 03/02/2014 | TT.1 |
| 6 | Thông tư liên tịch 01/2016/TTLT-TANDTC-VKSNDTC-BTP Hướng dẫn thi hành một số quy định của Luật hôn nhân và gia đình | | 06/01/2016 | 01/03/2016 | TL.1 |

Figure 4: Data in Phap Dien

| STT | Văn bản thuộc nội dung của đề mục | Cơ quan thực hiện pháp điển | Ngày ban hành | Ngày có hiệu lực | Ký hiệu văn bản trong đề mục |
|---|---|---|---|---|---|
| 1 | Luật 13/2022/QH15 Phòng, chống bạo lực gia đình | Bộ Văn hóa, Thể thao và Du lịch | 14/11/2022 | 01/07/2023 | |
| 2 | Nghị định 76/2023/NĐ-CP quy định chi tiết một số điều của Luật Phòng, chống bạo lực gia đình | Bộ Văn hóa, Thể thao và Du lịch | 01/11/2023 | 15/12/2023 | NĐ.1 |
| 3 | Quyết định 21/2016/QĐ-TTG Ban hành Quy chế phối hợp liên ngành về phòng, chống bạo lực gia đình | | 17/05/2016 | 15/07/2016 | QĐ.1 |
| 4 | Thông tư liên tịch 13/2016/TTLT-BGDĐT-BVHTTDL-BLĐTBXH-BCA Hướng dẫn thực hiện giáo dục chuyển đổi hành vi về xây dựng gia đình và phòng, chống bạo lực gia đình trong các cơ sở giáo dục thuộc hệ thống giáo dục quốc dân. | | 05/05/2016 | 21/06/2016 | TL.1 |
| 5 | Thông tư 24/2017/TT-BYT Quy định quy trình tiếp nhận, chăm sóc y tế và thống kê, báo cáo đối với người bệnh là nạn nhân bạo lực gia đình tại cơ sở khám bệnh, chữa bệnh | Bộ Y tế | 17/05/2017 | 07/07/2017 | TT.1 |
| 6 | Thông tư 07/2017/TT-BVHTTDL Thông tư quy định việc thu thập, báo cáo thông tin về gia đình và phòng, chống bạo lực gia đình. | Bộ Văn hóa, Thể thao và Du lịch | 29/12/2017 | 01/03/2018 | TT.2 |

Figure 5: Data in Phap Dien

## 3.3 Data Characteristics

- **Format:**: HTML format: Crawled or directly extracted from websites, with an average file size of 20–50 KB (mostly plain text). PDF format: Downloaded from official sources, with a file size of approximately 100–500 KB.
- **Content**: The dataset consists entirely of legal regulations, implementation guidelines, and detailed provisions related to the five subtopics within the domains of Population, Family, Children, Gender Equality, and Domestic Violence Prevention.

- **Language:**: All documents are in Vietnamese. above, corresponding to specific legal content groups (Children, Gender Equality, Population, Marriage and Family, and Prevention of Domestic Violence).
- **Length:**Each document ranges from a few pages to several dozen pages, depending on the document type (Laws are generally longer than Circulars).

### 3.4 Data Storage Methods

After collection, redundant sections are removed, and the data is stored as text files (.txt) to ensure simplicity and ease of processing.

Then, the data is split into individual articles, with each article stored as a single line, including metadata such as the law name, chapter title (if applicable), and section title (if applicable), in a JSONL file.

## 4 Text Analysis and Classification

### 4.1 Identifying Key Information/Topics for Classification

The collected documents were already categorized into specific sections on the source websites. Therefore, instead of using a model to classify the documents, we used a model to classify user queries. The selected topics correspond to the subcategories under Topic 8 of the "Phap Dien" database, including:

- Children
- Gender Equality
- Population
- Marriage and Family
- Prevention of Domestic Violence
- Others (topics not covered in the five categories above)

### 4.2 Classification Method

We used **PhoBERT**, a transformer-based model specifically trained for Vietnamese, to perform the classification task. The implementation process consists of the following key steps:

### 4.2.1 Data Collection

A dataset was collected containing user queries related to the six predefined topics:

- 818 queries on Children
- 500 queries on Gender Equality
- 624 queries on Population
- 864 queries on Marriage and Family
- 536 queries on Prevention of Domestic Violence
- 1015 queries on Others

### 4.2.2 Model Training

The collected dataset was divided into three subsets: training, validation, and test sets.

The model was trained with the following parameters:

- Optimizer: AdamW
- Learning rate: 2e-5
- Batch size: 16
- Epochs: 5
- Evaluation metrics: Accuracy, F1-score, and Loss

### 4.2.3 Model Performance Evaluation

On the validation set:

- Loss: 0.1633
- Accuracy: 96.33%
- F1-score: 96.31%

On the test set:

- Loss: 0.1943
- Accuracy: 96.02%
- F1-score: 96.04%

### 4.2.4 Results Analysis and Discussion

The **PhoBERT** model achieved a high accuracy of approximately **96%**, demonstrating its effectiveness in text classification.

The small performance gap between the validation and test sets indicates that the model does not suffer from overfitting.

**Limitations**:

- Some misclassifications may occur due to the similarity of the content between topics.
- The model may struggle with short or multi-topic queries.
- The dataset lacks diversity and may not fully generalize to different writing styles.

### 4.2.5 Conclusion

The **PhoBERT** model has proven to be effective in classifying user queries with high accuracy. However, further improvements can be made by:

- Collecting more data to expand the training set.
- Fine-tuning hyperparameters to optimize performance.
- Combining with other models to enhance recognition of complex queries.

# 5 Chatbot Deployment

## 5.1 Chatbot Design Description

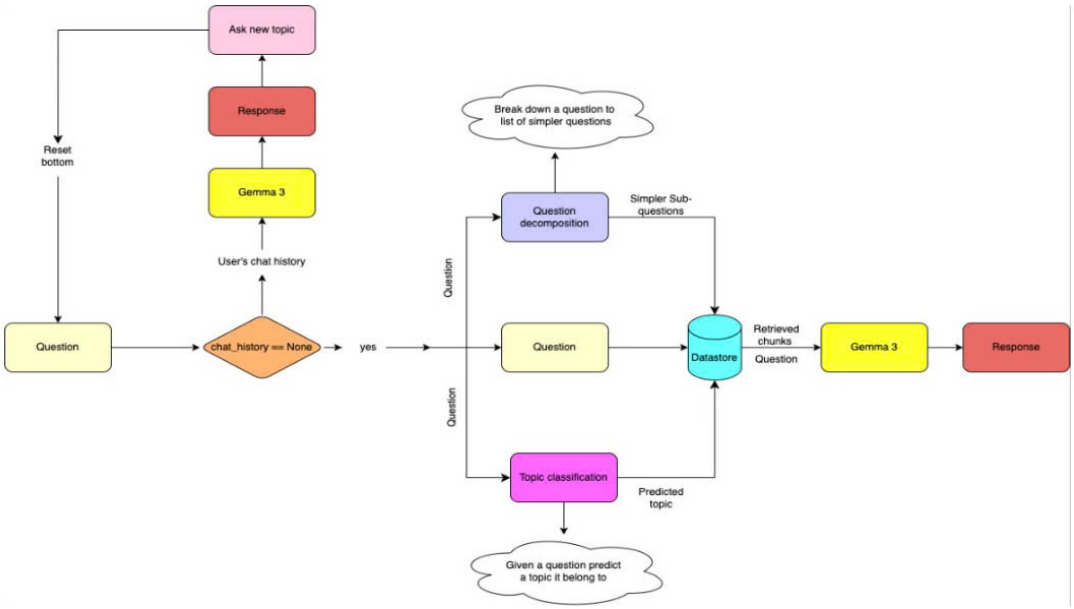



Figure 6: Pipeline chatbot

The chatbot is designed based on the RAG (Retrieval-Augmented Generation) architecture.

**Models used in the chatbot development process**

- Embedding model: Vietnamese-document-embedding
- Question segmentation model: Llama 3.2 3B
- Classification model: Pho-BERT
- Large Language Model (LLM): Gemma3 27B

After processing, the data is divided into chunks, embedded using the Vietnamese-document-embedding model, and stored in a vector database.

The chatbot receives a user query (a question), then passes it through the question segmentation model, which splits the original question into three smaller questions.

Each smaller question is processed by the classification model, which assigns it to one of six categories:

- Tre em (Children)
- Hon nhan va gia dinh (Marriage and Family)

- Binh dang gioi (Gender Equality)
- Dan so (Population)
- Phong chong bao luc gia dinh (Domestic Violence)
- Khac (Others)

Each smaller question is then embedded and searched in the vector database. The system retrieves k relevant chunks that contain useful information to answer these smaller questions.

The retrieved content is then compiled into a context, which is passed into the large language model (LLM). The model synthesizes the results and generates a final answer for the user.

## 5.2 Details on Chatbot Development

### 5.2.1 Embedding data and loading data into the database

After being crawled, the data is divided into chunks and stored as JSONL files, with each chunk representing an Article (iu) containing Text and Metadata. The Metadata includes the following components: Section (Mc), Chapter (Chng), and Law (Lut).

Additionally, the data is also stored in CSV format, with each row labeled accordingly. The CSV file contains the following columns:

- Dieu (Article)
- Muc (Section)
- Chuong (Chapter)
- Luat (Law)
- Nhan (Label)

**Libraries Used**: Faiss, Sentence Transformer

Each chunk is processed through the Vietnamese-document-embedding model to generate 768-dimensional vectors. These vectors are then stored in a new column Article Vector (Vector cua dieu) in the database.

Once embedding is complete, the data is indexed using the Faiss library and stored as a faiss.index file. This index significantly improves search efficiency within the vector database. When searching, we query the vectors based on the index, using Euclidean distance for retrieval.

### 5.2.2 Finetune the Llama 3.2 3B model for question decomposition

The Llama 3.2 3B model will be fine-tuned based on the pretrained model, with certain parameters adjusted to better fit the prepared dataset. The modifications are as follows:

- Pre-normalization replaces Post-normalization
- LayerNorm is replaced by RMSNorm
- Rotary Positional Embedding (ROPE) replaces Sinusoidal Positional Embedding
- Grouped Query Attention (GQA) replaces Multi-Head Attention (MHA)
- The activation function used is SiLU instead of ReLU

```
[
    {
        "content": "You are a helpful assistant that generates multiple sub-questions related to an
input question.\n The goal is to break down the input into a set of 3 sub-problems / sub-questions that
can be answered in isolation and must be an understandable stand-alone question.\n Generate multiple
search queries related to: Khi nào thì cha mẹ nên quyết định tham gia các chương trình sàng lọc trước
sinh và những yếu tố nào cần xem xét trước khi tham gia?\n Output (3 queries):\n **Respond format:**\n
Write a short analysis why they need to be decomposed into sub-questions and how it will be done to
derive final 3 decomposed sub-questions.\n [Sub-question 1, Sub-question 2, Sub-question 3]",
        "role": "system"
    },
    {
        "content": "Khi nào thì cha mẹ nên quyết định tham gia các chương trình sàng lọc trước sinh và
những yếu tố nào cần xem xét trước khi tham gia?",
        "role": "user"
    },
    {
        "content": "Câu hỏi này cần được phân tích và chia nhỏ thành các phần bởi vì nó liên quan đến
nhiều yếu tố như thời gian tham gia, tác động của sàng lọc, và các yếu tố cá nhân của cha mẹ. Để có
được câu trả lời toàn diện, cần tách thành ba câu hỏi riêng biệt: 1. Những lợi ích và rủi ro của việc
tham gia sàng lọc trước sinh là gì? 2. Thời điểm tốt nhất để tham gia các chương trình sàng lọc trước
sinh là khi nào? 3. Những yếu tố cá nhân nào cần được xem xét trước khi quyết định tham gia sàng lọc
trước sinh?\n ['Những lợi ích và rủi ro của việc tham gia sàng lọc trước sinh là gì?', 'Thời điểm tốt
nhất để tham gia các chương trình sàng lọc trước sinh là khi nào?', 'Những yếu tố cá nhân nào cần được
xem xét trước khi quyết định tham gia sàng lọc trước sinh?']",
        "role": "assistant"
    }
]
```

Figure 7: Instruction to finetune Llama model

More details on fine-tuning hyperparameters:

- Using LoRA with rank 128
- Training for 3 epochs
- Learning rate: 1e-4 with AdamW optimizer and cosine schedule
- Batch size: 16, Gradient Accumulation: 2 steps

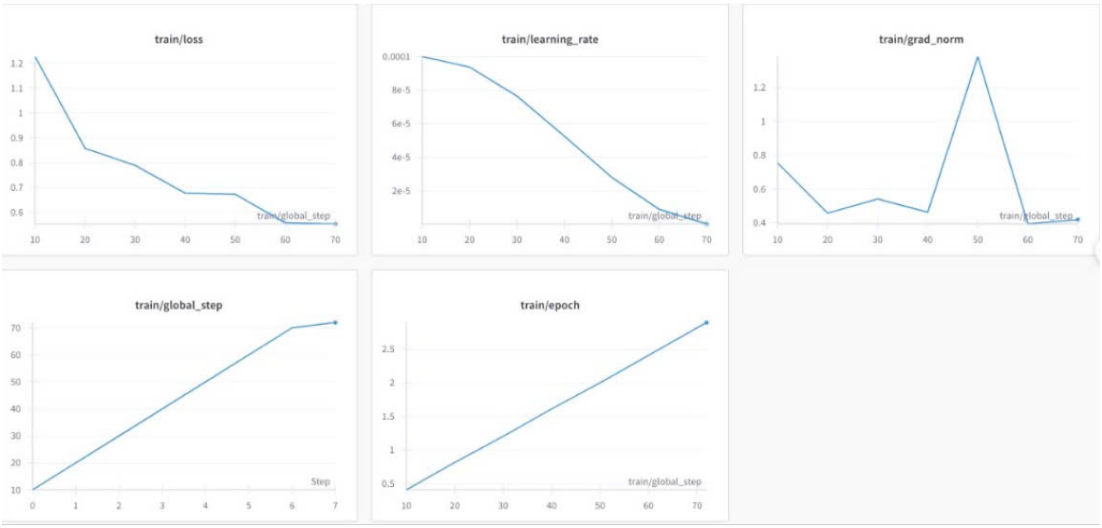



Figure 8: Training processing

### 5.2.3 Fine-tune the Pho-BERT model for question classification

The PhoBERT model will be retrained on the group's dataset with adjustments to certain parameters to improve performance. The specific settings are as follows:

- Learning rate: 2e-5
- Training batch size: 16
- Number of training epochs: 5
- Weight decay: 0.01

The model is trained to classify questions into six labels: Children, Gender Equality, Population, Marriage and Family, Prevention of Domestic Violence, Others

[955/955 08:05, Epoch 5/5]

| Epoch | Training Loss | Validation Loss | Accuracy | F1 |
|---|---|---|---|---|
| 1 | 0.400200 | 0.286856 | 0.943425 | 0.942863 |
| 2 | 0.197900 | 0.203414 | 0.952599 | 0.952506 |
| 3 | 0.043900 | 0.173278 | 0.960245 | 0.960109 |
| 4 | 0.088400 | 0.164618 | 0.964832 | 0.964705 |
| 5 | 0.070000 | 0.163281 | 0.963303 | 0.963149 |

Figure 9: Training result

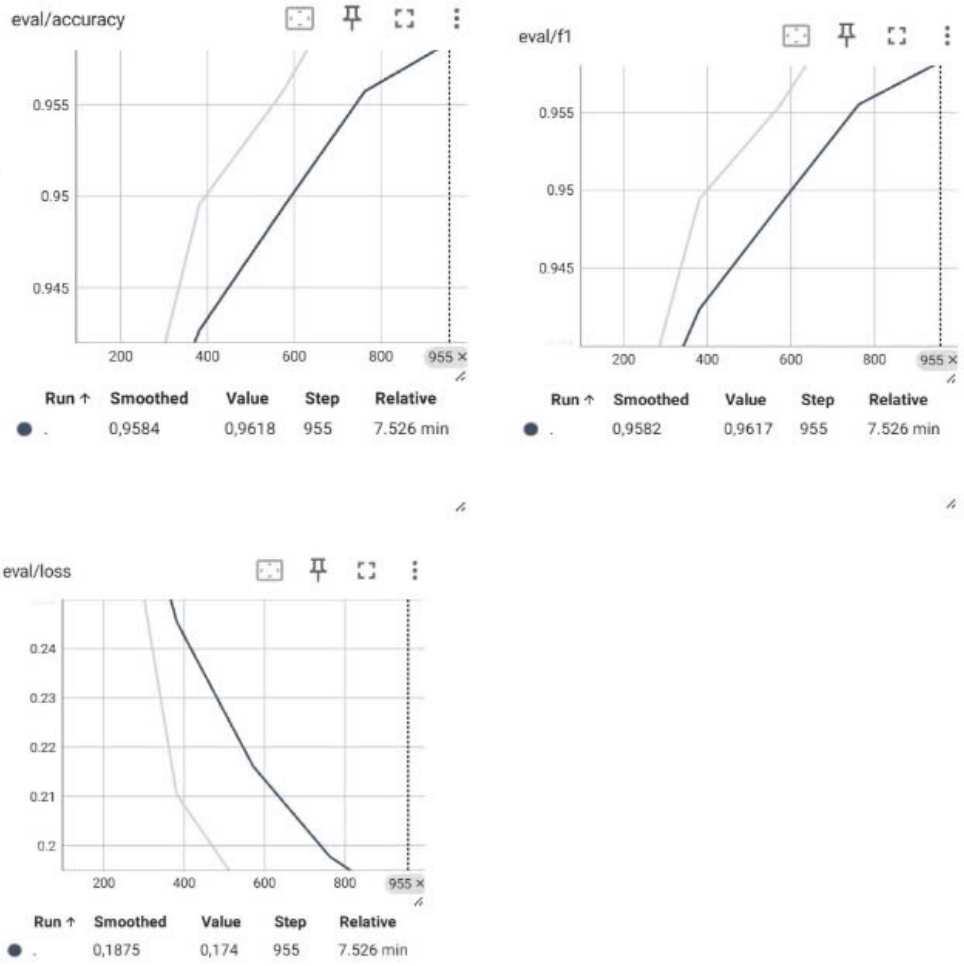



Figure 10: Training result

### 5.2.4 Chatbot Performance Evaluation

After training the models and integrating them into the chatbot, the chatbot will be evaluated using a dataset of multiple-choice and open-ended questions.

These questions will be collected from the internet as well as created by team members. The selected questions will be different from those in the training set to ensure an accurate assessment of the chatbot's performance.

| type | Question | Answer |
|---|---|---|
| MC | Trẻ em được định nghĩa là người dưới mấy tuổi?<br>A. Dưới 12 tuổi B. Dưới 14 tuổi C. Dưới 16 tuổi D. Dưới 18 tuổi | C |
| Open-ended | Tháng 6 là tháng hành động vì trẻ em được tạo ra nhằm mục đích gì? | Tháng hành động vì trẻ em được tổ chức vào tháng 6 hằng năm để thúc đẩy phong trào toàn dân chăm sóc, giáo dục và bảo vệ trẻ em; tuyên truyền, phổ biến, vận động cơ quan, tổ chức, cơ sở giáo dục, gia đình, cá nhân thực hiện chính sách, chương trình, kế hoạch, dự án, xây dựng các công trình và vận động nguồn lực cho trẻ em |

Figure 11: Question type

For multiple-choice questions, the team will evaluate the number of correct answers out of the total number of questions.

For essay questions, the team will use GPT-4o to assess the answers based on the original response.

For each question-answer pair, GPT-4o will be prompted to assign a score based on the following criteria:

- 0: Completely different
- 0.5: Contains fewer key points
- 0.8: Different wording but same meaning
- 1: Similar

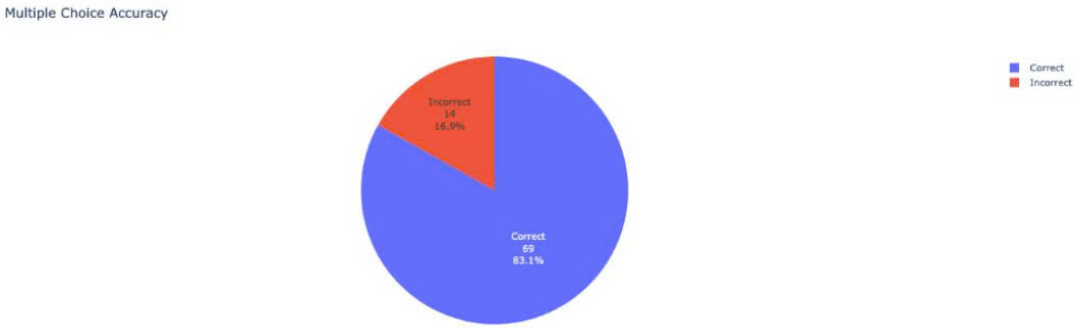



Figure 12: Multiple choice Accuracy

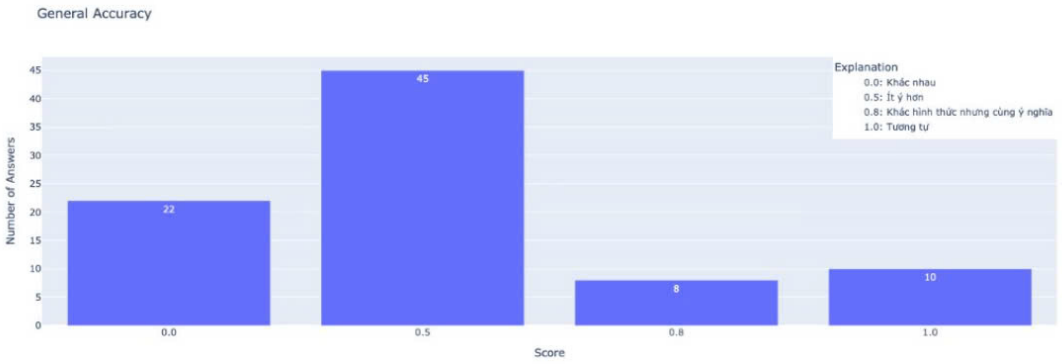



Figure 13: Open-ended Accuracy

Thus, the accuracy rate of essay questions is approximately 47%.

### 5.2.5 Discussion on possible improvements for the Chatbot

Based on the evaluation results above, the chatbot can answer most user queries. However, to further improve the evaluation results, the following solutions can be implemented:

- Enhancing the training dataset: The current dataset used for training is limited and lacks diversity. Improving both the quality and quantity of the data will help the chatbot achieve higher accuracy in answering questions.
- Expanding conversation flows: Designing multiple conversation threads will allow the chatbot to independently answer questions related to different topics. Additionally, enabling chat history storage will make it more convenient for users to continue previous discussions without having to re-establish the context from scratch.
- Improving the user interface: Enhancing the interface with more utilities will make the chatbot easier to use.
- Broadening legal topics: Incorporating a wider range of legal subjects will expand the chatbot's ability to provide relevant answers across different domains.
- Deploying on better hardware: Running the chatbot on optimized hardware will improve response times and reduce GPU rental costs.

# 6 Data Analysis, Summarization and Reporting

## 6.1 Model Decomposition Data

The data for fine-tuning the decomposition model is structured as follows:

- user_query: A hypothetical query from the user.
- analysis: How the model evaluates the user_query.
- decomposed_query: A list of smaller questions derived from the user_query.

### 6.1.1 Data statistics

This table provides some basic statistics about the dataset:

- Total rows: 773 → The dataset contains 773 question samples.
- Average length of user_query: 99.76 → On average, each user question has around 100 characters, indicating that the questions are relatively concise.

| | user_query | analysis | decomposed_query |
|---|---|---|---|
| 0 | Tôi đang phân vân về cách thức đảm bảo quyền l... | Câu hỏi này cần được phân tích thành các khía ... | [Nhà tuyển dụng có trách nhiệm gì trong việc đ... |
| 1 | Có cách nào để các cơ quan nhà nước và tổ chức... | Để trả lời câu hỏi này, chúng ta cần khám phá ... | [Các cơ quan nhà nước cần thực hiện những bước... |
| 2 | Tôi muốn biết các biện pháp nào cần thiết để g... | Câu hỏi này yêu cầu chúng ta phân tích nhiều y... | [Nhà trường cần làm gì để đảm bảo bình đẳng gi... |
| 3 | Trong bối cảnh việc làm, các doanh nghiệp phải... | Câu hỏi này yêu cầu chúng ta xem xét cả trách ... | [Doanh nghiệp có thể áp dụng những chính sách ... |
| 4 | Tôi muốn biết cách thức nào mà chính quyền có ... | Để hiểu rõ cách thức huy động sự tham gia, câu... | [Chính quyền có thể thực hiện các chiến dịch n... |

Figure 14: Data for decomposition model

| | Chỉ số | Giá trị |
|---|---|---|
| 0 | Tổng số dòng | 773.000000 |
| 1 | Độ dài trung bình user_query | 99.760673 |
| 2 | Độ dài trung bình analysis | 84.571798 |
| 3 | Số câu decomposed trung bình | 1.972833 |
| 4 | Số câu decomposed lớn nhất | 7.000000 |

Figure 15: Data for decomposition model

- Average length of analysis: 84.57 → The chatbot's analysis is slightly shorter than the original question, possibly because it focuses on key points.
- Average number of decomposed questions: 1.97 → On average, each question is split into nearly 2 sub-questions, suggesting a moderate level of decomposition.
- Maximum number of decomposed questions: 7 → Some questions are broken down into 7 sub-questions, indicating the complexity of certain queries.

Overall, the dataset maintains a balance between the original question, its analysis, and the level of detail in the decomposed questions.

### 6.1.2 Related graphs

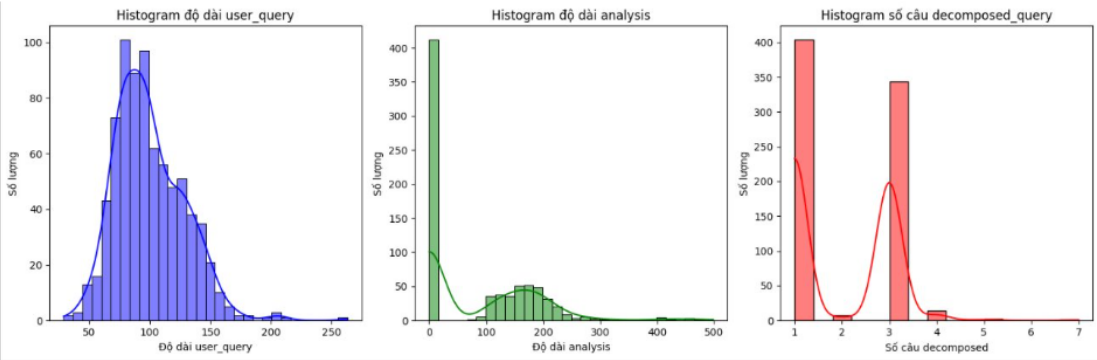



Figure 16: Data for decomposition model

**Histogram of user_query length (Left chart)**

- The distribution is nearly normal, with a peak around 80-120 characters.

- A few queries exceed 200 characters, but they are rare.
- This indicates that most user queries have a moderate length, neither too short nor too long.

**Histogram of analysis length (Middle chart)**

- Most analysis responses are very short (under 50 characters), but some extend to 300-500 characters.
- The distribution is right-skewed, suggesting that some analyses are significantly more detailed than others.
- A review may be needed to check for potential errors or inconsistencies in the analysis process.

**Histogram of decomposed_query count (Right chart)**

- Two clear peaks at 1 and 3 decomposed questions, indicating that most queries are split into either 1 or 3 sub-questions.
- Very few cases have more than 4 decomposed questions.
- This distribution suggests that the chatbot tends to generate a fixed number of decomposed questions, with 3 being the most common.

### 6.1.3 wordcloud of user_query

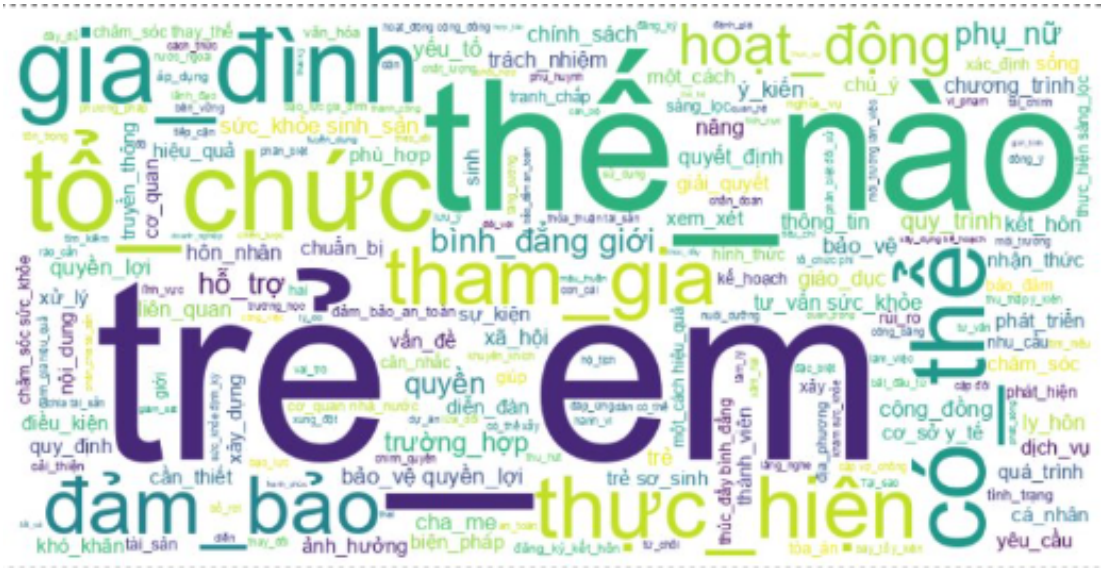



Figure 17: Data for decomposition model

**Prominent Keywords:**

- Frequently occurring words include ”tre em”(children), ”the nao”(how), ”gia inh”(family), ”to chuc”(organization), ”tham gia”(participate), and ”thuc hien”(implement). queries are split into either 1 or 3 sub-questions.
- This indicates that the content primarily focuses on children-related topics, organizational activities, rights, and implementation processes.

**Main Themes:**

- Keywords suggest a focus on child protection, family issues, gender equality, and support measures.
- Phrases such as ”dam bao”(ensure),”chinh sach”(policy),”quy trinh”(process), and”ho tro”(support) indicate that the content may relate to social policies or legal frameworks.
- This distribution suggests that the chatbot tends to generate a fixed number of decomposed questions, with 3 being the most common.

**Linguistic Structure:**

- The presence of many interrogative words like ”the nao”(how) and ”co the”(can) suggests that the dataset contains numerous questions or discussions on implementation methods.
- Verbs like ”thuc hien”(implement), ”tham gia”(participate), and ”am bao”(ensure) indicate an action-oriented content structure, often involving guidelines or proposed solutions.

### 6.1.4 Cosine Similarity between user_query and decomposed_queries

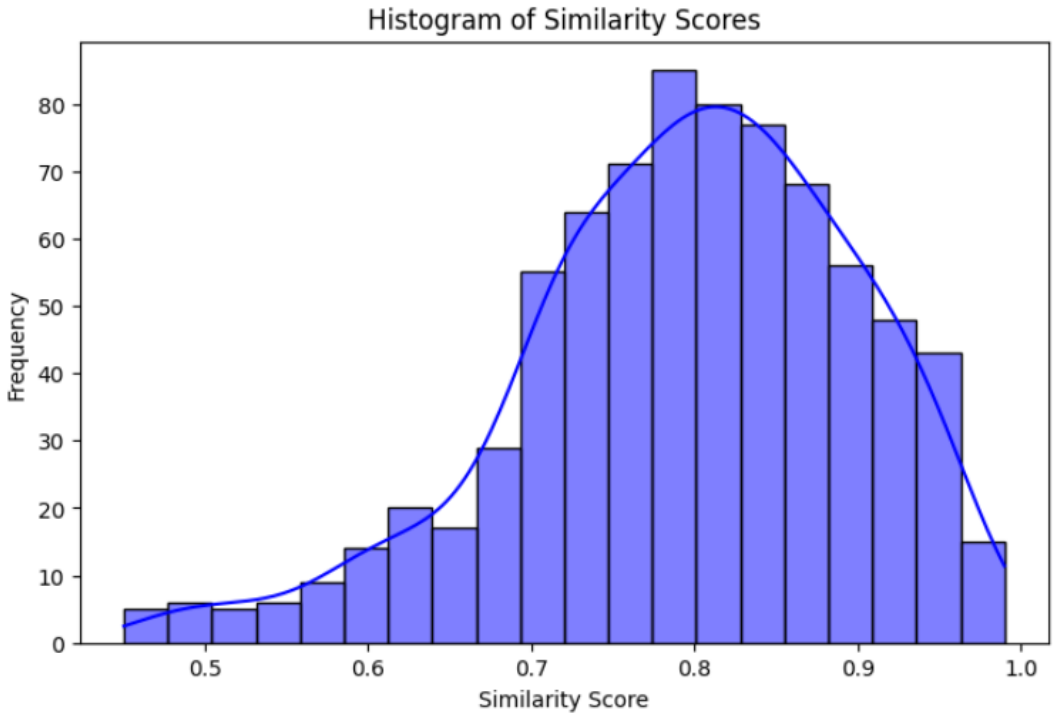



Figure 18: Data for decomposition model

**Score Distribution**

- The chart illustrates the distribution of similarity scores between user queries and decomposed sentences.
- Most similarity scores fall within the 0.7- 0.9 range, indicating that decomposed sentences are generally highly related to the original queries.

**Distribution Pattern**

- The similarity scores are right-skewed, with the majority concentrated between 0.7 and 0.9, gradually decreasing towards both ends.
- A small number of scores fall below 0.6, suggesting that some decomposed sentences do not closely match the original queries.

**Practical Implications**

- The decomposition system performs quite well,as most decomposed sentences retain the original meaning with high similarity scores.
- To further improve accuracy, it may be helpful to review cases with scores below 0.6 and analyze whether adjustments in the decomposition method are necessary.

## 6.2 Classification model data

This is the data used to finetune the label classification model for the user's query, the data has the following format:

### 6.2.1 Label distribution

The "Other" label has the largest number, which can cause data imbalance. The remaining labels are relatively evenly distributed but significantly lower. This imbalance can cause the model to favor predicting the "Other" label. Consider splitting the "Other" label or applying imbalance handling techniques such as oversampling or weight adjustment during training.

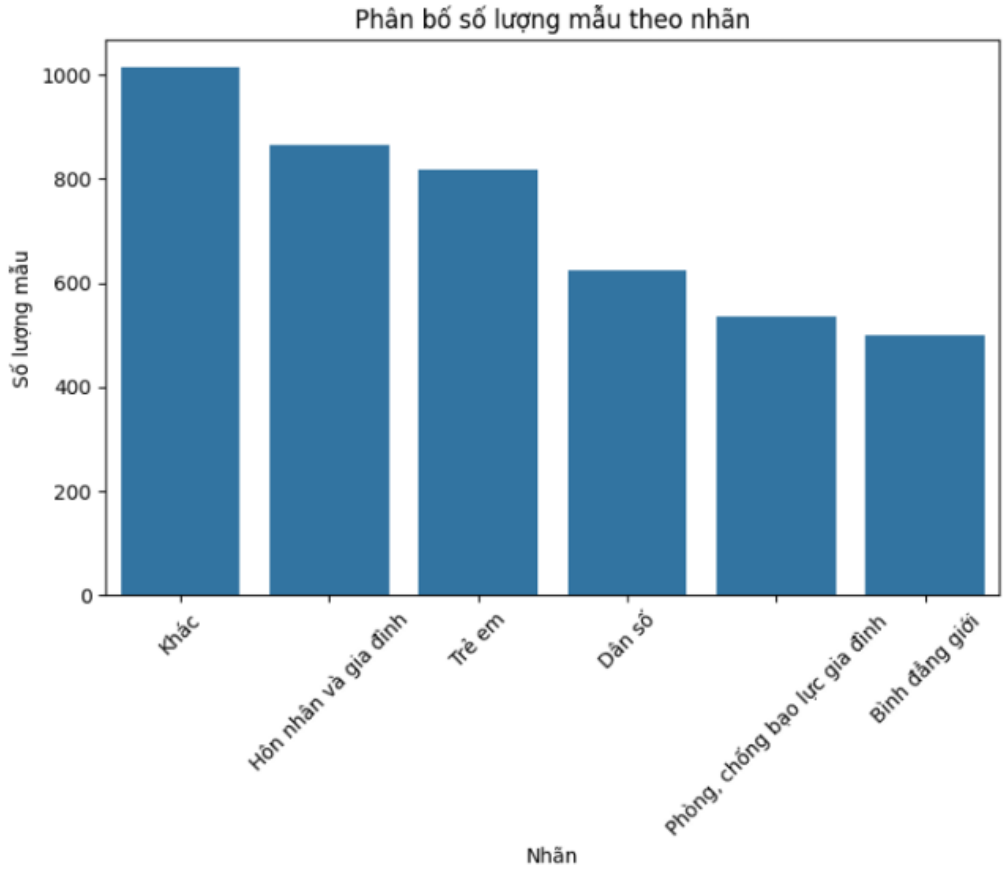



Figure 19: Data for classification model

### 6.2.2 Query length distribution

Most queries are between 10 and 18 words long, with a peak around 15-16 words. The distribution is right-skewed, meaning that there are a few very long queries (over 25 words). This shows that queries are generally short and to the point, which is suitable for NLP models. It is necessary to check whether longer queries are more informative or just contain unnecessary words. If necessary, query length can be truncated

or normalized to avoid affecting the model.

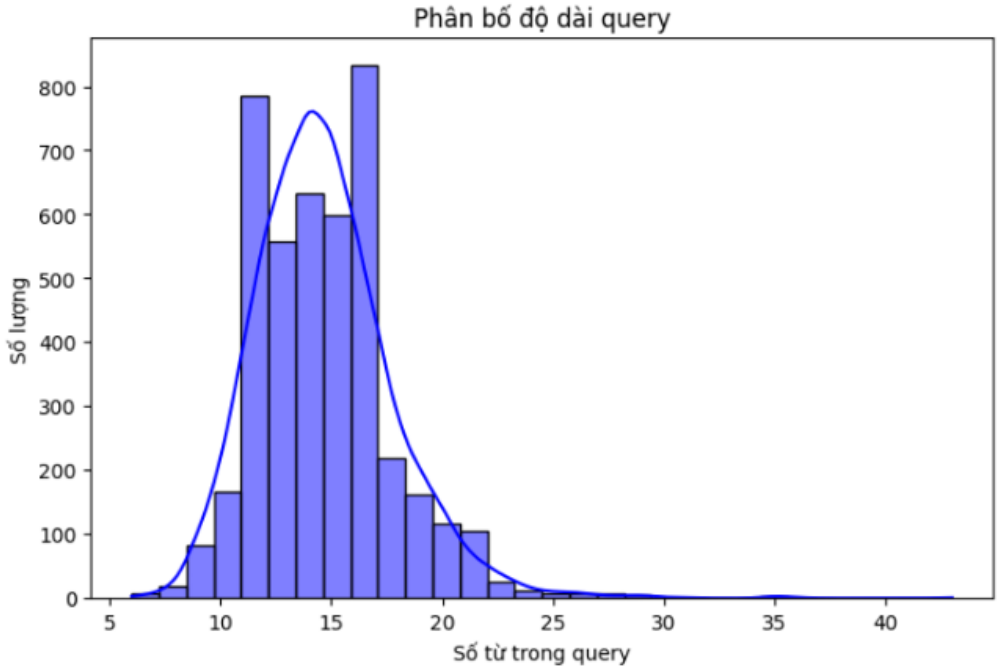



Figure 20: Data for classification model

### 6.2.3 Query wordcloud analysis

Common keywords include ”trach nhiem” (responsibility), ”quyen” (rights), ”the nao” (how), ”luat” (law), ”bao luc gia dinh” (domestic violence), ”tre em” (children), and ”gia dinh” (family). This indicates that the dataset focuses on legal issues, rights, and responsibilities. Terms like ”ho tro” (support), ”xu ly” (handling), and ”thuc hien” (implementation) suggest that queries often involve procedures, actions, or execution guidelines

Some keywords refer to specific target groups, such as ”tre em” (children), ”binh dang gioi” (gender equality), and ”chinh sach” (policy), indicating that the dataset covers various legal and social domains. This suggests that the model needs to understand the legal context and frequently asked questions about the law to accurately classify the query

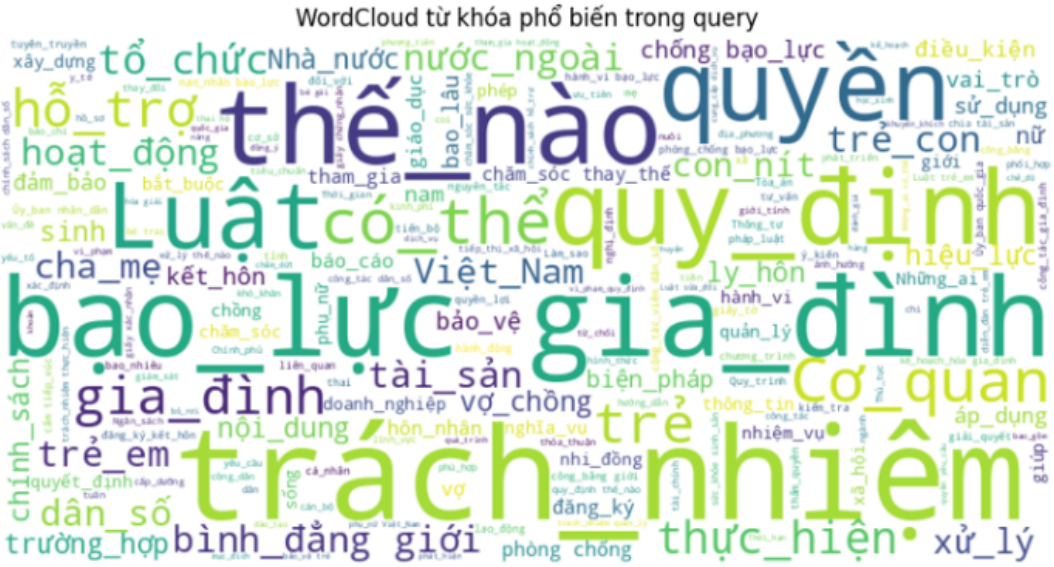



Figure 21: Data for classification model

### 6.2.4 Query statistical data analysis

**Mean (Average) Length**

- The"Gender Equality" label has the highest average query length (16.62 words), while the "Other" label has the shortest (12.78 words).
- This suggests that queries related to gender equality tend to be more detailed, while those classified as "Other" are generally more concise.

Standard Deviation (Std) The standard deviation ranges from 2.2 to 3.5, indicating that query lengths within each category do not vary significantly.

**Percentiles (25%, 50% - Median)**

- The median query length for "Gender Equality" is 16, meaning that half of the queries contain 16 words or fewer.
- The "Other" category has the lowest median (13 words), confirming that this group contains a higher proportion of shorter queries.
- Other categories, such as Children, Marriage & Family, and Population, have median values between 14-15, showing a consistent query length distribution across these groups.

## 6.3 Law data

The legal data includes the columns: Article (Dieu), Section (Muc), Chapter (Chuong), Law (Luat), Label (Nhan).

| | Article | Section | Chapter | Law | Label |
|---|---|---|---|---|---|
| 0 | Điều 1. Trẻ em\nTrẻ em là người dưới 16 tuổi.\n | NaN | Chương I NHỮNG QUY ĐỊNH CHUNG | LUẬT TRẺ EM | Trẻ em |
| 1 | Điều 2. Phạm vi điều chỉnh\nLuật này quy định ... | NaN | Chương I NHỮNG QUY ĐỊNH CHUNG | LUẬT TRẺ EM | Trẻ em |
| 2 | Điều 3. Đối tượng áp dụng\nCơ quan nhà nước, t... | NaN | Chương I NHỮNG QUY ĐỊNH CHUNG | LUẬT TRẺ EM | Trẻ em |
| 3 | Điều 4. Giải thích từ ngữ\nTrong Luật này, các... | NaN | Chương I NHỮNG QUY ĐỊNH CHUNG | LUẬT TRẺ EM | Trẻ em |
| 4 | Điều 5. Nguyên tắc bảo đảm thực hiện quyền và ... | NaN | Chương I NHỮNG QUY ĐỊNH CHUNG | LUẬT TRẺ EM | Trẻ em |

Figure 22: Law data

### 6.3.1 Statistics of quantity

| | Chủ đề | Luật | Nghị định (NĐ) | Nghị quyết (NQ) | Pháp lệnh (PL) | Quyết định (QĐ) | Thông tư (TT) |
|---|---|---|---|---|---|---|---|
| 0 | Trẻ em | 1 | 1 | 0 | 0 | 0 | 9 |
| 1 | Bình đẳng giới | 1 | 2 | 0 | 0 | 1 | 1 |
| 2 | Dân số | 0 | 4 | 0 | 1 | 2 | 12 |
| 3 | Hôn nhân và gia đình | 1 | 3 | 1 | 0 | 0 | 2 |
| 4 | Phòng chống bạo lực gia đình | 1 | 1 | 0 | 0 | 1 | 3 |

Figure 23: Detail of data

From the statistical table, we can see that most of the legal normative documents in the dataset are circulars. Circulars are guidelines issued by competent authorities for the implementation of laws. This indicates that the deployment of this chatbot project is essential to help people better understand the latest guidelines from government agencies, thereby avoiding unnecessary mistakes.

### 6.3.2 Number of chunks by label

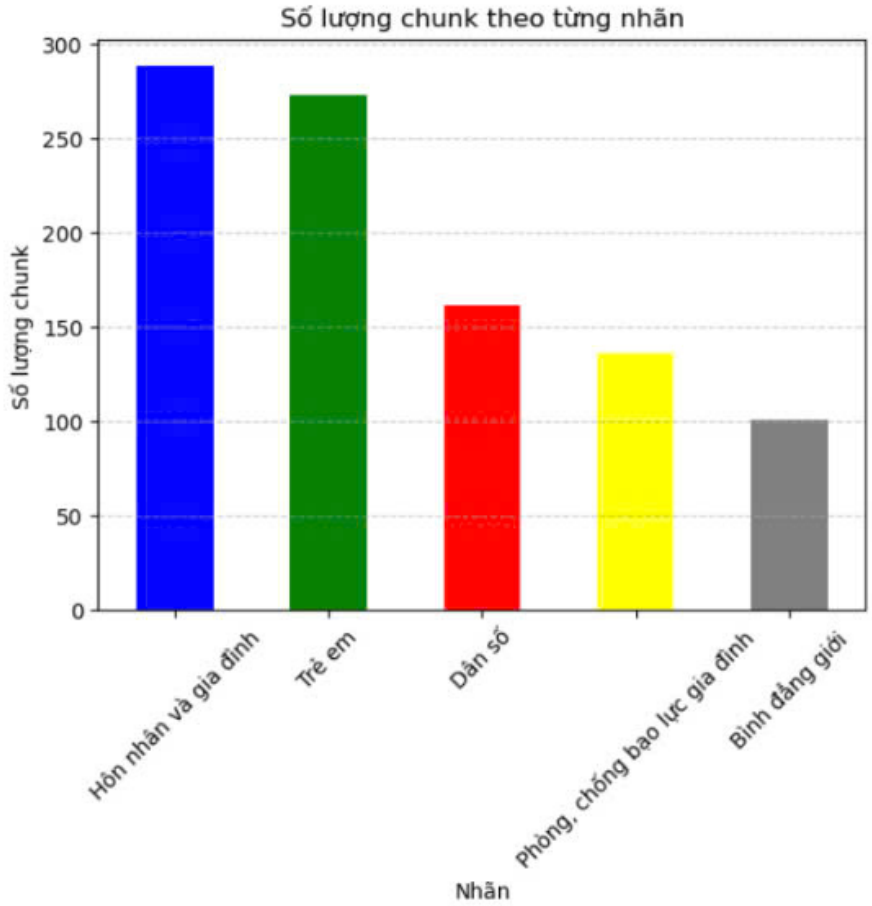



Figure 24: Number of chunks by label

| | Nhãn | Số lượng văn bản | Tỷ lệ (%) |
|---|---|---|---|
| 0 | Hôn nhân và gia đình | 288 | 30.03 |
| 1 | Trẻ em | 273 | 28.47 |
| 2 | Dân số | 161 | 16.79 |
| 3 | Phòng, chống bạo lực gia đình | 136 | 14.18 |
| 4 | Bình đẳng giới | 101 | 10.53 |

Figure 25: Number of chunks by label

From the bar chart and statistical table, we can see that the topic of Marriage and Family accounts for the largest proportion of the data. Meanwhile, the topic of Gender Equality has the lowest proportion, at only 10.53%. This indicates that marriage

and family are significant aspects of daily life, receiving considerable attention from governmental agencies in improving legal documents to enhance public awareness and contribute to a more civilized society.

### 6.3.3 Percentage of each type of law

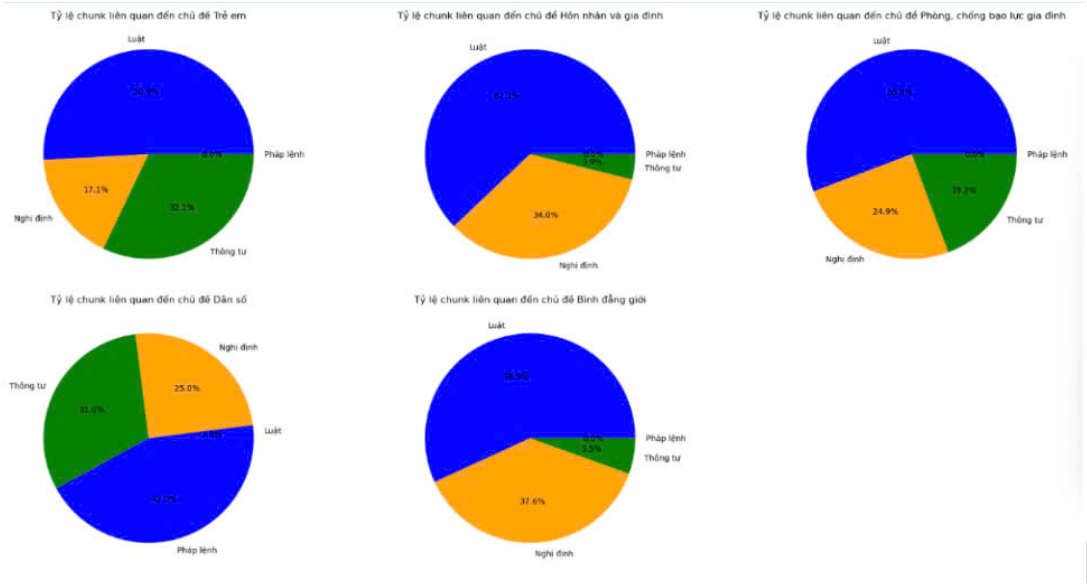



Figure 26: Percentage of each type of law

The five charts represent the percentage of data on Laws, Decrees, and Circulars across the five topics. The topic of Population does not have any legal documents, but it has a high percentage of Decrees and Circulars. This indicates that population-related issues are more practical in nature, and the government prioritizes guiding citizens to raise awareness of population policies rather than issuing theoretical legal documents.

### 6.3.4 Word cloud chart and word frequency distribution




Figure 27: Word cloud of data


```
{'Trẻ em': [('trẻ_em', 0.8465186401006156),
  ('chăm_sóc', 0.18180991863278828),
  ('tổ_chức', 0.13279740869170872),
  ('quy_định', 0.1152456314830789),
  ('thực_hiện', 0.11491446587536891)],
 'Hôn nhân và gia đình': [('hộ_tịch', 0.3108778992368931),
  ('kết_hôn', 0.2893606997536191),
  ('quy_định', 0.28321400461381063),
  ('tài_sản', 0.20387391112270767),
  ('gia_đình', 0.1913200988614572)],
 'Bình đẳng giới': [('giới', 0.6634594210984204),
  ('bình_đẳng', 0.4621833221882299),
  ('tổ_chức', 0.18466927442840975),
  ('thực_hiện', 0.18262872995958754),
  ('cơ_quan', 0.18160845772517642)],
 'Phòng, chống bạo lực gia đình': [('bạo_lực', 0.6009959673618782),
  ('gia_đình', 0.5684296874819309),
  ('phòng_chống', 0.22352009271620077),
  ('hành_vi', 0.16282534169143606),
  ('quy_định', 0.14881886068572114)],
 'Dân số': [('dân_số', 0.4179747410454844),
  ('thực_hiện', 0.25329687979884946),
  ('ml', 0.23869484014938352),
  ('tiếp_thị_xã_hội', 0.21819344283593953),
  ('gia_đình', 0.1688645865325663)]}
```


Figure 28: Word frequency

When using TF-IDF, we can observe the number of important words in each topic. This is also reflected in the Word Cloud chart above. Keywords such as ”children,” ”regulations,” ”domestic violence,” and ”gender” appear most frequently. This indicates that the government places great emphasis on issues related to children and domestic violence, meaning that legal documents on these two topics will continue to be improved.

# 7 Conclusion

## 7.1 Summary of key project results

After one month of developing the chatbot project, several achievements have been made:

- Transitioned from the Google Search method to the RAG (Retrieval-Augmented Generation) approach, optimizing retrieval capabilities and improving response accuracy. queries are split into either 1 or 3 sub-questions.
- Fine-tuned open-source models, reducing dependency on APIs from models like GPT or Gemini.
- Built a custom dataset for training and evaluating the chatbot.
- The chatbot achieved positive evaluation results, with an accuracy rate of 83.1% for questions related to the selected topics.
- Deployed on the cloud, enhancing performance and enabling simultaneous use by multiple users.

## 7.2 Project Contributions

The project has helped team members understand how to design, deploy, and optimize a chatbot model.

The project has also enabled class members to look up information related to Children, Marriage and Family, Gender Equality, Prevention of Domestic Violence, and Population.

## 7.3 Limitations and future development directions of the project

### 7.3.1 Existing limitations

- Response speed is not high, and the chatbot cannot stream answers in real time.
- Chat history is not optimally stored, especially when answering questions on multiple topics. The chatbot does not effectively utilize past conversations.

- Using an open-source embedding model reduces the chatbot's accuracy in generating responses.
- The training dataset lacks diversity, and the overall data quality is not high.
- The pipeline is not optimized, leading to higher hardware and operational costs when running the model.
- The chatbot cannot handle multiple users simultaneously; instead, it processes requests sequentially in a queue.

### 7.3.2 Future development directions of the project

- Diversify topics so that the chatbot can respond to a wider range of fields beyond the five mentioned above.
- Use a better embedding model and train the decomposition and classification models with more optimized parameters.
- Deploy the chatbot on a cloud with a more powerful GPU to improve response speed and accuracy.
- Redesign the pipeline to address the issue of chat history.
- Design a multi-user functionality that allows multiple users to interact with the chatbot simultaneously, optimizing the user experience.

# 8 References


Report Assignment *OPENAPI Group*, Available at: Link drive Assignment Report DPL302M.

PHMTung (2024) *DPL302M Train Dataset*, Available at: Hugging Face - DPL302M.

Ollama API Documentation, Available at: GitHub - Ollama API.

Research Paper, Available at: arXiv PDF.

Facebook Research FAISS, Available at: GitHub - FAISS.

Google Document, Available at: Google Docs.

Milvus Documentation, Available at: Milvus Quickstart.

Vietnamese Document Embedding, Available at: Hugging Face - Vietnamese Embedding.

Meta AI Llama 3.2, Available at: Hugging Face - Llama 3.2.

PhoBERT Base v2, Available at: Hugging Face - PhoBERT Base v2.

Qdrant Documentation, Available at: Qdrant.

Google Cloud Link, Available at: Google Cloud Link.